

Аналитический отчет

Прогнозирование эффективности противовирусных соединений методами классического машинного обучения

Постановка задачи

Данные содержат физико-химические и структурные признаки соединений, а также три целевые переменные:

- IC50 - концентрация полумаксимального ингибирования; меньшие значения соответствуют большей активности.
- CC50 - концентрация полумаксимальной цитотоксичности; большие значения указывают на меньшую токсичность.
- SI - индекс селективности; более высокие значения предпочтительны для отбора перспективных соединений.

В рамках анализа решаются следующие задачи:

1. исследовать распределения целевых переменных и структуру признаков;
2. построить регрессионные модели для IC50, CC50 и SI;
3. построить классификационные модели для превышения медианных значений IC50, CC50 и SI;
4. оценить способность моделей выделять соединения с $SI > 8$;
5. сформулировать практические выводы по применимости моделей.

Описание данных

После базовой очистки использовано 969 наблюдений. В таблице представлены три целевые переменные и набор числовых молекулярных дескрипторов. Пропуски в признаках обрабатывались медианным заполнением внутри обучающих пайплайнов, что снижает риск утечки информации между обучающей и тестовой выборками.

Показатель	Среднее	Медиана	Ст. откл.	Минимум	Максимум	Асимметрия
IC50, mM	220.726	45.338	397.172	0.004	4128.529	3.758
CC50, mM	586.420	424.166	633.624	0.701	4538.976	1.997
SI	73.968	3.900	695.565	0.011	15620.600	17.728

Исследовательский анализ данных

Распределения целевых переменных имеют выраженные правые хвосты. Средние значения заметно выше медиан, особенно для SI, что указывает на присутствие редких соединений с экстремально высоким индексом селективности.




Рисунок 1. Распределения IC50, CC50 и SI.

Показатель	Q1	Q3	Верхняя граница IQR	Выбросы	Доля выбросов
IC50, mM	12.515	231.373	559.660	138	14.2%
CC50, mM	99.999	891.777	2079.443	35	3.6%
SI	1.488	16.375	38.705	120	12.4%

По правилу межквартильного размаха наибольшая доля выбросов наблюдается для IC50 и SI. Это важно учитывать при выборе моделей: линейные методы могут быть чувствительны к экстремальным значениям, тогда как ансамбли деревьев обычно устойчивее к нелинейным зависимостям и выбросам.




Рисунок 2. Корреляция между целевыми переменными.

IC50 и CC50 имеют умеренную положительную связь. SI зависит от соотношения активности и токсичности, поэтому его связь с отдельными дескрипторами слабее и сложнее для прямого регрессионного моделирования.




Рисунок 3. Тепловая карта корреляций целевых переменных и топ-20 признаков.

Тепловая карта показывает высокую взаимную коррелированность части дескрипторов, связанных с размером и массой молекулы. Это подтверждает необходимость отбора признаков и контроля мультиколлинеарности при построении моделей.

Методология моделирования

Для моделирования использованы классические алгоритмы машинного обучения: линейные модели, метод ближайших соседей, деревья решений, Random Forest, Extra Trees, Gradient Boosting, логистическая регрессия и SVM. Для сопоставимости качества применялось фиксированное разбиение на обучающую и тестовую выборки, а подбор гиперпараметров выполнялся на обучающей части с использованием кросс-валидации.

В регрессионных задачах качество оценивалось по RMSE, MAE и R2. В классификационных задачах использовались Accuracy, F1-score и ROC-AUC. Для задач классификации порог медианы вычислялся по соответствующей целевой переменной, а для практической задачи селективности применялся фиксированный порог SI > 8.

Результаты регрессии

Цель	Лучшая модель	RMSE	MAE	R2	Интерпретация
IC50	ExtraTrees	397.217	191.158	0.280	умеренное качество
CC50	RandomFore st	461.797	276.525	0.470	лучшее качество среди задач регрессии
SI	GradientBoos ting	1133.066	116.621	-0.008	прогноз нестабилен




Рисунок 4. Сравнение качества регрессионных моделей для CC50.




Рисунок 5. Сопоставление фактических и прогнозных значений CC50.

Наиболее качественная регрессионная модель получена для CC50: Random Forest объясняет около 47% дисперсии тестовой выборки. Для IC50 качество ниже, но модель все еще улавливает часть структурных закономерностей. Для SI значение R^2 близко к нулю и отрицательно, поэтому прямой регрессионный прогноз индекса селективности не является надежным в текущей постановке.

Результаты классификации

Задача	Лучшая модель	Ассурасу	F1	ROC-AUC	Интерпретация
IC50 выше медианы	GradientBoosting	0.732	0.737	0.817	хорошее разделение классов
CC50 выше медианы	ExtraTrees	0.763	0.753	0.848	наиболее уверенная классификация
SI выше медианы	GradientBoosting	0.670	0.628	0.705	умеренное качество

SI > 8	ExtraTrees	0.696	0.576	0.745	практически полезная, но более сложная задача
--------	------------	-------	-------	-------	---




Рисунок 6. ROC-кривые моделей для классификации IC50 выше медианы.




Рисунок 7. ROC-кривые моделей для классификации CC50 выше медианы.




Рисунок 8. ROC-кривые моделей для классификации SI выше медианы.




Рисунок 9. ROC-кривые моделей для классификации $SI > 8$.

Классификационные модели демонстрируют более устойчивое качество, чем прямая регрессия SI. Лучшее разделение классов получено для CC50 выше медианы: ROC-AUC лучшей модели составляет около 0.848. Для IC50 результат также достаточно высокий. Задачи по SI сложнее, но модель $SI > 8$ сохраняет практическую ценность как предварительный фильтр перспективных соединений.

Ключевые выводы

- Физико-химические дескрипторы позволяют предсказывать CC50 заметно лучше, чем SI.
- Ансамблевые методы деревьев чаще дают лучшие результаты на табличных химических данных.
- SI имеет сильную асимметрию и экстремальные значения, что осложняет прямое регрессионное моделирование.
- Классификационная постановка для SI практически полезнее прямого прогноза его численного значения.

- Тепловая карта подтверждает мультиколлинеарность части дескрипторов, поэтому отбор признаков является важным этапом.

Практические рекомендации

Для первичного отбора соединений рекомендуется использовать классификационные модели как фильтр перспективных кандидатов, а регрессионные модели - как вспомогательный инструмент количественной оценки. Особое внимание следует уделять прогнозу CC50 и классификации SI > 8, поскольку эти задачи лучше связаны с практической оценкой безопасности и селективности соединений.

Для повышения качества дальнейшего анализа целесообразно расширить работу с признаками: проверить устойчивость отбора дескрипторов, рассмотреть логарифмические преобразования целевых переменных, добавить внешнюю валидацию и оценить модели на независимом наборе соединений.

Резюме

В работе проведен анализ набора данных химических соединений с молекулярными дескрипторами и целевыми показателями IC50, CC50 и SI. Основная цель исследования - оценить возможность прогнозирования противовирусной активности, цитотоксичности и селективности соединений с помощью классических алгоритмов машинного обучения.

Наиболее устойчивые результаты получены для классификационных постановок и для регрессии CC50. Прямая регрессия SI оказалась наименее стабильной из-за сильной асимметрии распределения и экстремальных значений индекса селективности.